


Фильтр Калмана

В ближайшие 2 главы мы рассмотрим очень эффектную идею, вошедшую в практику примерно одновременно с ЕМ-алгоритмом, который стал широко известен в 1970-х годах [1]. Речь пойдёт о фильтре Калмана [5], одном из центральных инструментов в обработке сигналов в робототехнике и различных приборах, включающих в себя датчики.

3.1 Выделение целевого сигнала из шума



Мы сейчас живём в мире, наполненном огромным количеством разных устройств. В том числе есть огромное количество маленьких простых устройств, которые обслуживают самые разные ежедневные потребности. Огромная развивающаяся быстрыми темпами область – интернет вещей (Internet of Things, IoT), где конструируются различные технические решения, основанные на локальном использовании небольших вычислительных устройств, состоящих из вычислительной единицы (микроконтроллер или микропроцессор) и системы датчиков: для замера температуры, освещённости, датчики геопозицио-

нирования (GPS или ГЛОНАСС), акселерометры и многое другое.

Проблема в том, что сами по себе датчики несовершенны, даже на мощных смартфонах вы столкнётесь с тем, что в подземном переходе или тоннеле геопозиционирование может быть сильно сложнее. Но и в обычных обстоятельствах в поле рядом со Сколтехом точность определения геопозиции по GPS может составлять 5-10 метров в зависимости от используемых датчиков. По этой же причине приложения замера пройденного расстояния, работающие от GPS выдают всегда не совсем точные данные.

Но ситуация бы была гораздо хуже, если бы не использовались дополнительно алгоритмы фильтрации сигнала, которые в предположении некоторой динамики системы помогают из нескольких шумных наблюдений уточнить настоящий сигнал. Знаковое первенство (хотя, говорят, что это было сделано на плечах гигантов) в изобретении таких решений для технических приложений принадлежит Рудольфу Калману и Ричарду Бюси, которые решили задачу при условии известной динамики в дискретном времени в 1960 [5] и немного позже в непрерывном в 1963. Одновременно этой задачей также занимались датский математик и астроном Николай Тиле, американский инженер Петер Сверлинг и советский математик Руслан Стратонович. В 1961 году Калман встречался со Стратоновичем в Москве[8], когда Стратонович успел опубликовать некоторое количество работ по этой теме (из них, в частности, [9, 10]). Стратонович и Калман дальше много переписывались, а сам Калман приезжал в СССР и Россию. Фильтр Калмана является частным случаем фильтров Стратоновича, которые разработаны для нелинейных систем в дискретном и непрерывном времени.

3.2 Задача фильтрации и извлечение сигнала

Представим себе, что у нас есть линейная модель


$$Y_{t+1} = AY_t + V_{t+1},$$

описывающая некоторую техническую систему (например, движение автомобиля или робота) в дискретном времени с точностью до некоторого шума V_t . Такая модель оказывается вполне неплохой как минимум для небольших временных масштабов, а далее можно предполагать, что будут меняться матрица A или параметры шума. Это реальный мир, но мы его наблюдаем через какие-то приборы (например, GPS-маячок), которые сигнал некоторым образом искажают и тоже добавляют свой шум:

$$X_{t+1} = BY_{t+1} + W_{t+1}.$$

Мы наблюдаем только набор X_t и хотели бы по максимуму избавиться от шума и попробовать оценить настоящий сигнал Y_t . При этом в зависимости от конкретного приложения нас может интересовать это оценивание в разном контексте:

1. *Задача фильтрации.* При известном X_t на ходу оценивать Y_t .
2. *Задача сглаживания.* При известном $X_{t-n}, \dots, X_t$ оценить $Y_{t-n}, \dots, Y_t$.
3. *Задача предсказания.* При известном $X_{t-n}, \dots, X_t$ оценить Y_{t+1} .



Оказывается, что в данных условиях универсальным решением является алгоритм, который носит название *фильтра Калмана* и был впервые описан Калманом в 1960 году [5], а после распространения ЕМ-алгоритма появились процедуры оценивания параметров этой и более общей нелинейной модели.

Как вообще поставить подобную задачу? Во всех трёх случаях нам надо

- при имеющейся информации (значения $X_{t_1}, \dots, X_{t_k}$) построить оценку $\hat{Y}_t$ значения Y_t ;
- при этом, в каком-то смысле оптимальную.

Если говорить на языке вероятности, то прогноз (или оценка) — это функция от доступных данных $\hat{Y}_t(X_1(\omega), \dots, X_k(\omega))$. С другой стороны, если говорить о критерии оптимальности, давайте возьмём привычное всем MSE (Mean Squared Error)

$$\mathbb{E} \left[\left\| Y_t - \hat{Y}_t(X_{t_1}(\omega), \dots, X_{t_k}(\omega)) \right\|_2^2 \right],$$

то есть, мы попробуем минимизировать квадрат отклонения от истины. Вообще, это что-то очень напоминает.

3.3 Простая модель наблюдений

Давайте остановимся и попробуем понять, что мы вообще хотим сделать. Раньше мы в статистике говорили об оценках параметров (чисел, которые просто не даны но где-то там в мире фиксированно есть), а теперь мы оцениваем случайную величину?..

Рассмотрим упрощённый, но очень показательный пример. В мире произошло великое событие: Саша выиграл X рублей. Сколько конкретно, никто точно не знает и каждый в своих независимых суждениях основывается на разных слухах. Если пойти по людям и спросить их, как им кажется, сколько выиграл Саша, каждый человек i скажет, что

$$Z_i = X + W_i.$$



По нашему дизайну $X, W_1, W_2, \dots$ независимы, с нулевым матожиданием и дисперсиями $\mathbb{E}[X^2] = a^2$, $\mathbb{E}[W_j^2] = m^2$. Саша может и проиграть, но лотерея всегда устраивается так, что гарантированного выигрыша в среднем у участника нет. Как получить искомую оценку? Для начала попробуем сконструировать линейную оценку, то есть, оценку из класса

$$\mathcal{L}_k = \left\{ \sum_{i=1}^k c_i Z_i : c_i \in \mathbb{R} \right\}.$$

Это формально линейное подпространство большего Гильбертова пространства $L^2(P)$ (можно воспринимать как величины с конечным вторым моментом): там есть скалярное произведение через интеграл

$$\langle X, Y \rangle = \mathbb{E}[XY].$$

В этом смысле поиск наилучшей оценки при информации $Z_1, \dots, Z_k$ — это на самом деле задача поиска ортогональной проекции $\mathcal{P}_{\mathcal{L}_k}(X)$ на конечномерное подпространство $\mathcal{L}_k$.

Вообще Z_j зависимы через X , поэтому в качестве базиса для ортогональной проекции не очень удобны, хотя они действительно линейно независимы. Чтобы упростить задачу поиска проекции, можно применить процедуру Грама-Шмидта. Так мы конструируем

$$A_1 = Z_1$$

и далее

$$A_j = Z_j - \sum_{i=1}^{j-1} \frac{\langle Z_j, A_i \rangle}{\langle A_i, A_i \rangle} A_i = Z_j - \sum_{i=1}^{j-1} \frac{\mathbb{E}[Z_j A_i]}{\mathbb{E}[A_i^2]} A_i.$$

В новом ортогональном базисе проекции считать сильно проще, проекцией будет

$$\hat{X}_k = \sum_{i=1}^k \frac{\mathbb{E}[X A_i]}{\mathbb{E}[A_i^2]} A_i,$$

где мы посчитали коэффициенты при элементах нового базиса как

$$c_i = \frac{\mathbb{E}[XA_i]}{\mathbb{E}[A_i^2]}.$$

Если вернуться к процессу ортогонализации, один шаг – это вычисление

$$A_j = Z_j - \mathcal{P}_{\mathcal{L}_{j-1}}(Z_j) = Z_j - \mathcal{P}_{\mathcal{L}_{j-1}}(X),$$

последнее происходит из-за того, что A_i и W_j независимы, если $i < j$ и поэтому $\mathbb{E}[A_i W_j] = 0$. Из этого также следует интересное наблюдение:

$$\mathbb{E}[XA_j] = \mathbb{E}[(X - \hat{X}_{j-1})^2].$$

То есть, оказывается, новую оценку (при данных $Z_1, \dots, Z_k$) можно получить путём некоторой линейной коррекции старой (при данных $Z_1, \dots, Z_{k-1}$) с помощью уже известной в момент k невязки $Z_k - \hat{X}_{k-1}$:

$$\hat{X}_k = \hat{X}_{k-1} + \frac{\mathbb{E}[(X - \hat{X}_{k-1})^2]}{\mathbb{E}[(X - \hat{X}_{k-1})^2] + m^2}(Z_k - \hat{X}_{k-1}).$$

Проанализируем получившееся матожидание, добавив $\pm \hat{X}_{k-1}$:

$$S_k = \mathbb{E}[(X - \hat{X}_k \pm \hat{X}_{k-1})^2] = S_{k-1} + \mathbb{E}[(\hat{X}_k - \hat{X}_{k-1})^2] - 2\mathbb{E}[(X - \hat{X}_{k-1})(\hat{X}_k - \hat{X}_{k-1})].$$

Почти всё мы уже видели, например,

$$\mathbb{E}[(\hat{X}_k - \hat{X}_{k-1})^2] = \frac{S_{k-1}^2}{(S_{k-1} + m^2)^2} \mathbb{E}[(Z_k - \hat{X}_{k-1})^2]$$

и

$$\mathbb{E}[(X - \hat{X}_{k-1})(\hat{X}_k - \hat{X}_{k-1})] = \mathbb{E}[X(\hat{X}_k - \hat{X}_{k-1})] = \frac{S_{k-1}}{S_{k-1} + m^2} \mathbb{E}[X(Z_k - \hat{X}_{k-1})] = \frac{S_{k-1}^2}{S_{k-1} + m^2},$$

и ещё

$$\mathbb{E}[(Z_k - \hat{X}_{k-1})^2] = \mathbb{E}[(X + W_k - \hat{X}_{k-1})^2] = S_{k-1} + m^2.$$

Если собрать это вместе, то мы получим уравнение на S_k

$$S_k = S_{k-1} - \frac{S_{k-1}^2}{S_{k-1} + m^2}.$$

На каждом шаге мы можем пересчитывать новое значение S_k основываясь на предыдущем. Таким образом, мы получили совсем простую процедуру вычисления нового значения, уточнённого с помощью невязки предыдущего прогноза. Конкретнее, с приходом нового наблюдения Z_j алгоритм действий такой:

1. Вычислить новый прогноз

$$\hat{X}_k = \hat{X}_{k-1} + \frac{S_{k-1}}{S_{k-1} + m^2}(Z_k - \hat{X}_{k-1});$$

2. Вычислить его ожидаемую квадратичную ошибку

$$S_k = S_{k-1} - \frac{S_{k-1}^2}{S_{k-1} + m^2}.$$

Остаётся только вычислить старт:

$$\hat{X}_1 = \frac{a^2}{a^2 + m^2} Z_1,$$

по определению ортогонального базиса Z_1 – это первый ортогональный элемент. И не забываем про

$$S_1 = \mathbb{E} \left[(X - \hat{X}_1)^2 \right] = \frac{a^2 m^2}{a^2 + m^2},$$

который вычисляется подстановкой $\hat{X}_1$.

Оказывается, можно даже получить чёткую формулу $\hat{X}_k$, без рекуррентного отношения. Можно подумать, что стоит попробовать искать решение в виде $\hat{X}_k = \alpha_k \sum_{j=1}^k Z_j$. Это ортогональная проекция тогда и только тогда, когда $X - \hat{X}_k$ ортогонально Z_i для всех $i \leq k$. В смысле L^2 это даёт

$$\mathbb{E} \left[(X - \hat{X}_k) Z_i \right] = \mathbb{E} \left[\left(X - \alpha_k \sum_{j=1}^k Z_j \right) Z_i \right] = a^2 - \alpha_k (ka^2 + m^2) = 0.$$


Это должно равняться нулю, поэтому

$$\alpha_k = \frac{a^2}{ka^2 + m^2},$$

что приводит к

$$\hat{X}_k = \frac{a^2}{a^2 + m^2/k} \frac{1}{k} \sum_{j=1}^k Z_j.$$

Видно, что это не совсем обычное предсказание выборочным средним. Если m^2 небольшое относительно a^2 , то достаточно быстро мы получим, что прогноз примерно равен выборочному среднему наблюдений (верим в данные, потому что шум слабый, можем примерно прикинуть выигрыш), а если наоборот большое, то на начальных этапах наблюдения вообще игнорируются и прогноз близок к нулю (верим в матожидание, шум очень большой, из данных ничего особо не ясно, наверное, Саша ничего не выиграл). И в любом случае в силу закона больших чисел при $k \rightarrow \infty$ прогноз почти наверное сойдётся к... X – тому, что мы хотим оценивать (шумы усредняются в 0 по усиленному закону больших чисел).



3.4 Найти условное матожидание

Итак, общая картина теперь более ясна: где-то там в мире есть настоящая динамика $Y_1(\omega), \dots, Y_t(\omega), \dots$, мы её наблюдаем как $X_1(\omega), \dots, X_t(\omega), \dots$ и хотели бы понять, чему примерно равняется $Y_t(\omega)$ если доступна информация о некоторых X .

На самом деле то, что мы искали, — это условное матожидание

$$\hat{Y}_t = \mathbb{E}[Y_t \mid X_1, \dots, X_t],$$

а матожидание квадратичной ошибки в общем случае — ковариационная матрица ошибок

$$P_t = \mathbb{E}[(Y_t - \hat{Y}_t)(Y_t - \hat{Y}_t)^T \mid X_1, \dots, X_t].$$

Попробуем обобщить идеи выше на наш случай. Вспомним модель:

$$Y_{t+1} = AY_t + V_{t+1} \quad (\text{мир}),$$


$$X_{t+1} = BY_{t+1} + W_{t+1} \quad (\text{наблюдения}),$$

а также зададим стартовое условие $Y_1 \sim N(\xi, \Lambda)$. Предположим, что все шумы $V_t \sim_{iid} N(0, R_Y)$ и $W_t \sim_{iid} N(0, R_X)$ и независимы. Давайте пока что как и раньше займёмся фильтрацией и будем оценивать Y_t по значениям $X_1, \dots, X_t$. Метод для фильтрации был такой: получать новую оценку $\hat{Y}_t$ на основе старой $\hat{Y}_{t-1}$ с коррекцией на невязку.

Прежде чем переходить к записи алгоритма, попробуем понять его устройство. Алгоритм Калмана в том, чтобы сначала построить априорный прогноз на основе прошлого прогноза

$$\tilde{Y}_t = A\hat{Y}_{t-1}.$$

В отличие от предыдущего случая, вместо X у нас теперь изменяющийся процесс Y_t , поэтому прогноз тоже делается с учётом того, что статичности нет и динамика поменяет Y_{t-1} на Y_t .



Потом этот прогноз, как и раньше, нужно уточнить, потому что нам пришло новое наблюдение X_t . С помощью него производится фильтрация. Конкретнее, делается линейная коррекция с помощью невязки:

$$\hat{Y}_t = \tilde{Y}_t + K_t(X_t - B\tilde{Y}_t).$$

Матрица K_t (её ещё называют *Kalman Gain*) выбирается на каждом шаге своя и такая, чтобы минимизировать квадрат ошибки прогноза

$$K_t = \arg \min_K \mathbb{E} \left[\left\| \hat{Y}_t - Y_t \right\|_2^2 \mid X_1, \dots, X_{t-1} \right],$$

где условие в матожидании отражает тот факт, что мы используем информацию о значениях $X_1, \dots, X_{t-1}$. Таким образом, K_t выбирается для лучшего взвешивания априорного прогноза и невязки. А как мы уже помним, решение этой задачи есть ортогональная проекция на подходящее подпространство (попробуйте подумать, с каким базисом!). Точно так же мы поступали в простом примере выше, подбирая правильный вес перед невязкой. Эта задача из-за полной линейности всего комфортно решается. Конкретно нужно взять производную по матрице K_t , для этого удобно записать скалярное произведение через следы и разложить выражение на более простые компоненты:

$$\begin{aligned} \mathbb{E} \left[\left\| \hat{Y}_t - Y_t \right\|_2^2 \mid X_1, \dots, X_{t-1} \right] &= \mathbb{E} \left[\text{tr} \left\{ (\hat{Y}_t - Y_t)(\hat{Y}_t - Y_t)^T \right\} \mid X_1, \dots, X_{t-1} \right] = \\ &= \mathbb{E} \left[\text{tr} \left\{ (\tilde{Y}_t - Y_t + K_t(X_t - B\tilde{Y}_t))(\dots)^T \right\} \mid X_1, \dots, X_{t-1} \right] = \\ &= \mathbb{E} \left[\text{tr} \left\{ (\tilde{Y}_t - Y_t + K_tB(Y_t - \tilde{Y}_t) + K_tW_t)(\dots)^T \right\} \mid X_1, \dots, X_{t-1} \right]. \end{aligned}$$

Набираемся сил и не спеша раскрываем скалярный квадрат (три точки для краткости, обозначают то же выражение, что слева).

$$\begin{aligned} &= \mathbb{E} \left[\text{tr} \left\{ (\tilde{Y}_t - Y_t)(\dots)^T + K_tB(\tilde{Y}_t - Y_t)(\dots)^T B^T K_t^T + K_tW_tW_t^T K_t^T - \right. \right. \\ &\quad \left. \left. - K_tB(\tilde{Y}_t - Y_t)(\dots)^T - (\tilde{Y}_t - Y_t)(\dots)^T B^T K_t^T \right\} \mid X_1, \dots, X_{t-1} \right]. \end{aligned}$$

Мы сразу можем удалить кросс-слагаемые с W_t , используя независимость и его нулевое матожидание. Матрица

$$\tilde{P}_t = \mathbb{E} \left[(\tilde{Y}_t - Y_t)(\tilde{Y}_t - Y_t)^T \mid X_1, \dots, X_{t-1} \right] -$$

это ковариационная матрица ошибок априорного прогноза при условии полученного наблюдения X_t . С ней разберёмся отдельно, это несложно. В остальном мы получили

$$= \text{tr} \left\{ \tilde{P}_t \right\} + \text{tr} \left\{ K_t B \tilde{P}_t B^T K_t^T \right\} + \text{tr} \left\{ K_t R_x K_t^T \right\} - \left\{ K_t B \tilde{P}_t \right\} - \left\{ \tilde{P}_t B^T K_t^T \right\}.$$

Это число, нам его надо потимизировать по K . Более того, это квадратичная функция по K и можно при должной сноровке показать, что она выпукла (следовательно мы найдём минимум после решения условия первого порядка). Здесь нам помогает уже известные нам приёмы дифференцирования:

$$\partial_X \text{tr}(XAX^T) = (A^T + A)X^T, \quad \partial_X \text{tr}(XA) = A.$$

Здесь использовалась колоночная нотация (numerator). Далее, понемногу вычисляем производную по K_t и приравниваем к нулю (не забываем, что у нас много симметричных матриц):

$$\partial_{K_t} : 2B\tilde{P}_t B^T K_t^T + 2R_x K_t^T - 2B\tilde{P}_t = 0$$

Приходим к выражению

$$K_t = \tilde{P}_t B^T (B\tilde{P}_t B^T + R_x)^{-1}.$$

Через матрицу $\tilde{P}_t$ мы можем вычислить ковариационную матрицу апостериорных прогнозов (подставьте частично вычисленный K_t в оптимизируемое выражение, но без следа):

$$P_t = \mathbb{E} \left[(\hat{Y}_t - Y_t)(\hat{Y}_t - Y_t)^T \mid X_1, \dots, X_t \right] = \dots = \tilde{P}_t - K_t B \tilde{P}_t.$$

Матрицы $\tilde{P}_t$ и P_t – важный технический ингредиент и побочный продукт, которые мы можем использовать для построения доверительных интервалов прогнозов.

Остаётся последний штрих:

$$\begin{aligned} \tilde{P}_t &= \mathbb{E} \left[(\tilde{Y}_t - Y_t)(\tilde{Y}_t - Y_t)^T \mid X_1, \dots, X_{t-1} \right] = \\ &= \mathbb{E} \left[(A\hat{Y}_{t-1} - AY_{t-1} - V_t)(A\hat{Y}_{t-1} - AY_{t-1} - V_t)^T \mid X_1, \dots, X_{t-1} \right]. \end{aligned}$$

Оказывается, что если не спешить всё раскрывать, это красиво сворачивается в

$$\tilde{P}_t = AP_{t-1}A^T + R_y.$$

Итак, общая схема такая: изначально задаётся $\tilde{Y}_1 = \xi$, $\tilde{P}_1 = \Lambda$, а далее (пропустив на первой итерации первые два шага) в цикле по $t = 2, 3, \dots$

$$\begin{aligned} \tilde{Y}_t &= A\hat{Y}_{t-1} \quad (\text{априорный прогноз}), \\ \tilde{P}_t &= AP_{t-1}A^T + R_y \quad (\text{ошибка априорного прогноза}), \\ K_t &= \tilde{P}_t B^T (B\tilde{P}_t B^T + R_x)^{-1} \quad (\text{фильтр}) \\ \hat{Y}_t &= \tilde{Y}_t + K_t(X_t - B\tilde{Y}_t) \quad (\text{апостериорный прогноз}), \\ P_t &= \tilde{P}_t - K_t B \tilde{P}_t \quad (\text{ошибка апостериорного прогноза}). \end{aligned}$$

Что такое прогноз $\hat{Y}_t$? Это в точности условное матожидание (потому что это решение задачи наименьших квадратов), а P_t – ковариационная матрица ошибок апостериорного прогноза:

$$\hat{Y}_t = \mathbb{E}[Y_t \mid X_1, \dots, X_t], \quad P_t = \mathbb{E}[(Y_t - \hat{Y}_t)(Y_t - \hat{Y}_t)^T \mid X_1, \dots, X_t].$$

То есть, мы не только получили прогноз значения Y_t в виде $\hat{Y}_t$, но ещё и оценку неопределённости, потому что по конструкции

$$Y_t \mid X_1, \dots, X_t \sim \mathcal{N}(\hat{Y}_t, P_t).$$

Если вы заметили, есть один интересный момент, связанный с тем, что при выборе K_t оптимизировалась ковариация при условии $Y_1, \dots, Y_{t-1}$. Но оценка $\hat{Y}_t$ действительно является условным матожиданием, а P_t – условной ковариацией при условии $Y_1, \dots, Y_t$, это следует из того, что $\hat{Y}_t$ строится как проекция на подпространство, порождённое $X_1, \dots, X_{t-1}$ и невязкой $X_t - B\tilde{Y}_t$, которые ортогональны. Иными словами,

$$\mathbb{E}[Y_t \mid X_1, \dots, X_t] = \mathbb{E}[Y_t \mid X_1, \dots, X_{t-1}, X_t - B\tilde{Y}_t],$$

аналогичное верно и про ковариацию. Предоставим вам проверить этот момент, это ещё одна необычная деталь вывода, которая часто упускается из вида и найти её можно разве что в классике временных рядов [2, Гл. 4.3]. В этом источнике метод вывода основан на теореме о нормальной корреляции и сильно отличается.

3.5 Универсальный ответ


Подытожим: мы решили задачу фильтрации, вычислив прогноз $\hat{Y}_t$ и какую-то оценку ошибки прогноза. Но фильтр Калмана – это на самом деле устройство, которое способно решать все три поставленные задачи. Более того, в гауссовской модели, как у нас, это будет оптимальным с точки зрения дисперсии подходом.

1. *Задача фильтрации.* Мы уже умеем: Двигаемся по времени и вычисляем по алгоритму $\hat{Y}_t$ при получении нового наблюдения X_t .
2. *Задача предсказания.* Можно догадаться, что предсказание – это тот самый шаг априорного прогноза: $\tilde{Y}_t = \mathbb{E}[Y_t \mid X_1, \dots, X_{t-1}]$. На самом деле, фильтр Калмана можно интерпретировать как Байесовскую модель (точнее Байесовскую векторную авторегрессию $VAR(1)$), потому что на выходе мы получаем ещё и оценку неопределённости.
3. *Задача сглаживания.* Вот тут сложнее. Но в какой-то момент была статья [7], где построили очень похожий алгоритм, но в обратную сторону по времени, который

по именам авторов называли RTSS (Rauch-Tung-Striebel smoother (RTSS)). Этот алгоритм применяется после фильтрации и уточняет все сделанные ранее оценки, получая сглаженные оценки $\bar{Y}_t$. Это возможно благодаря тому, что ковариационные матрицы ошибок априорных прогнозов вычислялись при условии $X_1, \dots, X_t$, с известным наблюдением в момент t . Детальнее, алгоритм такой: задать $\bar{Y}_T = \hat{Y}_T$, $\bar{P}_T = P_T$, а далее в цикле $t = T - 1, \dots, 1$ выполнять

$$\begin{aligned} S_t &= P_t A^T (\tilde{P}_{t+1})^{-1} \quad (\text{вычисление сглаживающего фильтра}), \\ \bar{Y}_t &= \hat{Y}_t + S_t (\bar{Y}_{t+1} - \tilde{Y}_{t+1}) \quad (\text{сглаживание}), \\ \bar{P}_t &= P_t + S_t (\bar{P}_{t+1} - \tilde{P}_{t+1}) S_t^T \quad (\text{ошибка сглаживания}). \end{aligned}$$

По смыслу $\bar{Y}_t = \mathbb{E}[Y_t \mid X_1, \dots, X_T]$, а матрица $\bar{P}_t = \mathbb{E}[(Y_t - \bar{Y}_t)(Y_t - \bar{Y}_t)^T \mid X_1, \dots, X_T]$. Методология построения алгоритма сглаживания такая же, как и у алгоритма фильтрации: новая уточнённая оценка строится как линейная коррекция фильтрованного значения с помощью невязки.



ЕМ-алгоритм: оценка фильтров

В этой лекции мы попробуем разобраться, как ЕМ-алгоритм помогает оценивать параметры для модели фильтрации и фильтра Калмана.

4.1 Оценка параметров: вывод правдоподобия

Рассмотрим в деталях модель системы; при этом мы без потери основного смысла существенно упростим вычисления: в оригинальной статье Калмана ещё добавлялись управляющие воздействия, которые вносили смещение в шум. Реальные состояния эволюционируют в соответствии с

$$Y_{t+1} = AY_t + V_{t+1},$$

где Y_t, V_t принимают значения в $\mathbb{R}^n$, при этом V_t – это последовательность шумов. Модель наблюдений тоже линейна и со своим шумом:

$$X_{t+1} = BY_{t+1} + W_{t+1}, \quad -$$

про неё мы также предполагаем, что X_t принимает значения в $\mathbb{R}^n$. Матрицы A, B без ограничений, но они должны быть совместимы по размерностям. Про шумы предполагается, что они в совокупности независимы, $V_t \sim \mathcal{N}(0, R_y)$ и $W_t \sim \mathcal{N}(0, R_x)$.

Таким образом, мы имеем вероятностную модель, в которой параметрами θ являются матрицы A, B , ковариационные матрицы векторов шума R_x, R_y , а также параметры стартового состояния $Y_1 \sim \mathcal{N}(\xi, \Lambda)$. Данные включают в себя только набор $X_1, \dots, X_n$; переменные $Y_1, \dots, Y_n$ не наблюдаются.

Время ЕМ-алгоритма! Мы, как и раньше, начинаем с того, что записываем функцию


$$Q(\theta^0|\theta) := \mathbb{E}_{\theta^0} [\ln p_\theta(X, Y) \mid X]$$

и понимаем, что так легко разбить зависимости и выписать условные вероятности, как в случае смеси не получится. Вместо этого мы пойдём более неспешным путём и не будем пока избавляться от матожиданий $\mathbb{E}_{\theta^0} [\cdot \mid X]$.

Начнём с того, что перепишем в точности выражение под знаком матожидания:

$$\ln p_\theta(X, Y) = \ln p_\theta(X|Y) + \ln p_\theta(Y).$$

В данном случае помогает знание зависимостей в величинах X, Y , которые обозначены на рисунке.



Первое слагаемое получается преобразовать как

$$\ln p_\theta(X|Y) = \ln p_\theta(X_1, \dots, X_{n-1}|X_n, Y) + \ln p_\theta(X_n|Y) = \ln p_\theta(X_1, \dots, X_{n-1}|Y) + \ln p_\theta(X_n|Y_n)$$

и это приводит к привычной сумме

$$\ln p_\theta(X|Y) = \sum_{i=1}^n \ln p_\theta(X_i|Y_i).$$

Что касается второго, скрытый сигнал Y существует по своей динамике и мы видим что-то похожее на случай цепей Маркова из Лекции 0 (и это не случайность):

$$\ln p_\theta(Y) = \ln p_\theta(Y_1) + \sum_{i=1}^{n-1} \ln p_\theta(Y_{i+1}|Y_i).$$

Таким образом, получается лог-правдоподобие из трёх компонент, в каждую из которых входят свои параметры, общих параметров они не имеют:

$$\ln p_\theta(X, Y) = \sum_{i=1}^n \ln p_\theta(X_i|Y_i) + \sum_{i=1}^{n-1} \ln p_\theta(Y_{i+1}|Y_i) + \ln p_\theta(Y_1).$$

Первая очень похожа на правдоподобие гауссовской линейной модели регрессии, вторая – на уже ранее виденную модель авторегрессии (но векторной), а третья связана с неопределённостью стартового состояния.

Если мы воспользуемся теперь явным видом распределений и соберём константы в одну общую константу, получим

$$\begin{aligned} Q(\theta^0|\theta) = & \text{const} - \\ & - \frac{n}{2} \ln \det R_x - \frac{1}{2} \mathbb{E}_{\theta_0} \left[\sum_{i=1}^n \left((X_i - BY_i)^T R_x^{-1} (X_i - BY_i) \mid X \right) \right] - \\ & - \frac{n}{2} \ln \det R_y - \frac{1}{2} \mathbb{E}_{\theta_0} \left[\sum_{i=1}^{n-1} (Y_{i+1} - AY_i)^T R_y^{-1} (Y_{i+1} - AY_i) \mid X \right] - \\ & - \frac{1}{2} \ln \det(\Lambda) - \frac{1}{2} (Y_1 - \xi)^T \Lambda^{-1} (Y_1 - \xi). \end{aligned}$$

Здесь очень много всего, но тем не менее есть структура, а если предположить, что все нужные матожидания можно вычислить (мы чуть позже увидим, как именно), то можно явно промаксимизировать по параметрам $\theta = \{A, B, R_x, R_y, \xi, \Lambda\}$. Заметьте, что матожидания берутся по модели данных с параметрами θ^0 , поэтому мы можем вносить производные по θ под знак матожидания.

4.2 Оценка параметров: М-шаг

Все вычисления достаточно технические, их можно без проблем проделать самому, если уметь вычислять матричные производные. Нужные формулы вспомним на ходу. Поскольку шумы гауссовские, то оказывается, что можно в правильном порядке провести дифференцирование, приравнять производные к нулю и получить аналитическое точное решение. Хорошей идеей оказывается адресовать параметры авторегрессионной и регрессионной частей отдельно.

Оптимизируем по A . Матрица A входит только в авторегрессионную компоненту; помним, что дифференцирование можно внести под матожидание, потому что матожидание берётся по модели с A^0 , а не с A . Смотрим на выражение и понимаем, что здесь нам понадобится знакомые с прошлой лекции формула (1)

$$\partial_X \text{tr}(AX) = A$$

и формула (2)

$$\partial_X \text{tr}(XAX^T) = X^T(A + A^T),$$

а также формула (3), которую мы не выводили, но можно сделать это самому:

$$\partial_X \text{tr}(XBX^TR) = BX^TR + B^TX^TR^T.$$

Применим, отбросив не зависящие от A члены:

$$\begin{aligned} \partial_A Q &= \partial_A \mathbb{E}_{\theta^0} \left[\frac{1}{2} \sum_{i=1}^{n-1} (Y_{i+1}^T R_y^{-1} Y_{i+1} - Y_i^T A^T R_y^{-1} Y_{i+1} - Y_{i+1}^T R_y^{-1} A Y_i + Y_i^T A^T R_y^{-1} A Y_i) \mid X \right] = \\ &= \sum_{i=1}^{n-1} (\mathbb{E}_{\theta^0} [Y_i Y_{i+1}^T \mid X] R_y^{-1} - \mathbb{E}_{\theta^0} [Y_i Y_i^T \mid X] A^T R_y^{-1}). \end{aligned}$$

Если приравняем к нулю и произведём сокращения, то получим, что оптимальная

$$A = \left(\sum_{i=1}^{n-1} P_{i+1,i} \right) \left(\sum_{i=1}^{n-1} P_{i,i} \right)^{-1}, \quad P_{i,i} = \mathbb{E}_{\theta^0} [Y_i Y_i^T \mid X], \quad P_{i+1,i} = \mathbb{E}_{\theta^0} [Y_{i+1} Y_i^T \mid X],$$

тут мы впервые ввели для краткости новое обозначение $P_{i,i}$ и $P_{i+1,i}$.

Оптимизируем по R_y . Здесь нам понадобится знакомая по гауссовскому ММП формула (3) для

$$\partial_C \ln \det(C) = (C^T)^{-1}.$$

В итоге получим

$$\partial_{R_y} Q = -\frac{n-1}{2} R_y^{-1} + \frac{1}{2} \sum_{i=1}^{n-1} (R_y^{-1} P_{i+1,i+1} R_y^{-1} - R_y^{-1} A P_{i,i+1} R_y^{-1} - R_y^{-1} P_{i+1,i} A^T R_y^{-1} + R_y^{-1} A P_{i,i} A^T R_y^{-1})$$

и, приравняв к нулю и сократив лишнее, придём к результату

$$R_y = \frac{1}{n-1} \sum_{i=1}^{n-1} (-A P_{i,i+1} - P_{i+1,i} A^T + P_{i+1,i+1} + A P_{i,i} A^T).$$


Оптимизируем по B и R_x . Здесь всё происходит абсолютно по тем же принципам, но возникнут произведения X и Y . Выпишем просто ответ:

$$B = \left(\sum_{i=1}^n \widetilde{x} y_i \right) \left(\sum_{i=1}^n P_{i,i} \right)^{-1}, \quad R_x = \frac{1}{n} \sum_{i=1}^n \left(X_i X_i^T + B P_{i,i} B^T - B \widetilde{x} y_i^T - \widetilde{x} y_i B^T \right),$$

где мы по аналогии с $P_{i,i}$ ввели

$$\widetilde{x} y_i = \mathbb{E}_{\theta^0} [X_i Y_i^T \mid X].$$

В итоге. Мы получили формулы для вычисления М-шага, но проблема в том, что все они зависят от матожиданий, которые мы пока не вычисляли. На первый взгляд это кажется сложной задачей, потому что самый прямой подход требует вычисления условного распределения по аналогии с тем, как мы делали в случае смесей.



4.3 Алгоритм фильтрации Калмана

Не случайность, что ровно такие матожидания вычислялись в фильтре Калмана! Конкретнее, в алгоритме RTSS (сглаживание). Если мы будем использовать алгоритм Калмана и RTSS, на выходе мы получим ровно нужные величины и завершим конструкцию ЕМ-алгоритма. Его можно будет пробовать запускать.

Вспомним модель как раньше, но с известными параметрами $A, B, R_x, R_y, \Lambda, \xi$ (они нам даны в θ_0 , такова конструкция ЕМ-алгоритма).

$$\begin{aligned} Y_{t+1} &= AY_t + V_{t+1}, \quad V_{t+1} \sim \mathcal{N}(0, R_y), \\ X_{t+1} &= BY_{t+1} + W_{t+1}, \quad W_{t+1} \sim \mathcal{N}(0, R_x). \end{aligned}$$

4.3.1 Финальный алгоритм

Фильтрация. Итак, алгоритм фильтрации Калмана. Задаём из параметров θ_0 (по конструкции ЕМ-алгоритма они даны) $\hat{Y}_1 = \xi, P_1 = \Lambda$, а далее в цикле по t

$$\begin{aligned} \tilde{Y}_t &= A\hat{Y}_{t-1} \quad (\text{априорный прогноз}), \\ \tilde{P}_t &= AP_{t-1}A^T + R_y \quad (\text{ошибка априорного прогноза}), \\ K_t &= \tilde{P}_t B^T (B\tilde{P}_t B^T + R_x)^{-1} \quad (\text{фильтр}) \\ \hat{Y}_t &= \tilde{Y}_t + K_t(X_t - B\tilde{Y}_t) \quad (\text{апостериорный прогноз}), \\ P_t &= \tilde{P}_t - K_t B \tilde{P}_t \quad (\text{ошибка апостериорного прогноза}). \end{aligned}$$

Сглаживание. Фильтрации нам мало, потому что она вычисляет только

$$\hat{Y}_t = \mathbb{E}[Y_t \mid X_1, \dots, X_t],$$

то есть, условное матожидание при условии моментов времени до t . Чтобы уточнить старые прогнозы фильтрации применяют алгоритм сглаживания (RTSS), а ещё дополнительно нам нужно вычислять ковариацию значений с лагом (детали опустим, формулу нужно получать из RTSS). По инструкции: задать $\bar{Y}_T = \hat{Y}_T, \bar{P}_T = P_T$, а далее в цикле $t = T - 1, \dots, 1$ выполнять

$$\begin{aligned} S_t &= P_t A^T (\tilde{P}_{t+1})^{-1} \quad (\text{вычисление сглаживающего фильтра}), \\ \bar{Y}_t &= \hat{Y}_t + S_t(\bar{Y}_{t+1} - \tilde{Y}_{t+1}) \quad (\text{сглаживание}), \\ \bar{P}_t &= P_t + S_t(\bar{P}_{t+1} - \tilde{P}_{t+1})S_t^T \quad (\text{ошибка сглаживания}), \\ V_{t+1,t} &= S_t \bar{P}_t, \quad (\text{лаг-1 ковариация, для } t \leq T - 1) \end{aligned}$$

Финальная схема. Остаётся только понять, как алгоритм фильтрации помогает построить ЕМ-алгоритм. Если вернуться немного назад, то интересные матожидания можно найти в расчётах:

$$P_{i,i} = \bar{P}_i + \hat{Y}_i \hat{Y}_i^T, \quad P_{i+1,i} = V_{i+1,i} + \hat{Y}_{i+1} \hat{Y}_i^T,$$

а кросс-члены в силу известных наблюдений X задаются как


$$\widetilde{yx}_i = \hat{Y}_i X_i^T.$$

Итоговый ЕМ-алгоритм выглядит теперь так:

1. Инициализировать $\theta^0 = \{A, B, R_x, R_y, \xi, \Lambda\}$;
2. Пока не остановимся:
 - (а) Е-шаг: Вычислить матожидания для параметров θ^0 , используя алгоритм фильтрации и сглаживания;
 - (б) М-шаг: вычислить новые параметры θ по выведенным формулам.

4.3.2 Проблемы

...такой алгоритм может не сойтись. Если оценивать всё, то в системе очень много степеней свободы. Заметьте, к примеру, что матрицы A и B могут друг друга компенсировать и друг под друга подгоняться. Например, на шаге 10 матрица A диагональная с 10 на диагонали, матрица B – с числом $1/10$; если они поменяются местами и правильно пересчитаются ковариационные матрицы R_x, R_y , то правдоподобие не изменится. На практике это соответствует тому, что наблюдатель Y меряет в килограммах интересное значение, а наблюдающий X меряет значение в тоннах; а на более поздней итерации наоборот. Чтобы избежать этой проблемы достаточно зафиксировать одну из матриц, например, единичной. К счастью, в любой задаче для фильтра у вас уже есть априорная информация, позволяющая оценивать только часть неизвестных параметров. В этом случае алгоритм уже сойдётся и так будет выглядеть его результат после 100 итераций (доверительный интервал уровня 0.975 построен с использованием оценки апостериорной ошибки):



На этой картинке изображена задача фильтрации GPS датчика из семинара. В качестве наблюдений дана только координата (скорость не замеряется), требуется оценить траекторию и скорость объекта в каждый момент времени. На левом графике показан результат для координаты, а на правой – для скорости. Если вдруг вы линейный скептик (и не верите в линейные модели), фильтр Калмана – тот самый случай, когда линейная модель способна на по-настоящему реальные вещи.

Нелинейность: расширенный фильтр Калмана (ЕКФ)

В этой лекции мы посмотрим внимательнее на модельное предположение линейности и обсудим, до какой степени мы можем обобщить оригинальный алгоритм фильтра Калмана.

5.1 Проблемы линейной модели

Фильтр Калмана – действительно по-настоящему мощная линейная модель и может сложиться впечатление, что для него нет нерешаемых задач. До какой-то степени это действительно верно, но как и любой метод, он обладает некоторыми недостатками и для определённых задач невозможно их полностью игнорировать.

- **Нелинейность.** Так складывается, что по построению многие практические модели оказываются нелинейными. Учитывая, как далеко прошли технологии в области средств передвижения, навигации и измерений, это неудивительно. Хотите применить фильтрацию – нужно учитывать конструктивные особенности.
- **Негауссовость.** Несмотря на достаточное удобство гауссовского распределения, некоторые процессы устроены по-другому. В частности, это касается моделей, используемых в финансовой математике, а также в актуарных расчётах.

Но от этого задача фильтрации не становится невыполнимой и уж точно не теряет своей актуальности. Наоборот, всё становится ещё интереснее и появляется много вопросов о том, как именно в своей задаче учитывать эти ограничения, чтобы адаптировать к ним общую методологию.

Пример 5.1. *(Путёвки за границу Великобритании [2, Гл.14]) Логарифмирование и переход к лог-приращениям – один из самых популярных приёмов в анализе временных рядов. Однако, даже после него могут оставаться сезонные и трендовые компоненты, которые приводят к нелинейной системе. В качестве примера рассматриваются наблюдения за количеством выездов жителей Соединённого Королевства с января 1980 до декабря 2006, собранные Национальной службой статистики (ONS). Уже на первых графиках (здесь мы их приводим для полноты) видно, что логарифмирование не очень помогает.*




Иллюстрация из примера: на графике выше показано число выездов (в миллионах), ниже – логарифмированный ряд, масштаб данных месячный

В статье [6] рассматривается следующая модель (логарифмированного либо исходного) ряда:

$$y_t = \mu_t + \exp(c_0 + c_\mu \mu_t) \gamma_t + \varepsilon_t, \quad \varepsilon_t \sim N(0, \sigma_\varepsilon^2), \quad t = 1, \dots, n,$$

где c_0, c_μ неизвестные коэффициенты. Процесс μ_t – это процесс локального линейного тренда

$$\begin{aligned} \mu_{t+1} &= \mu_t + \nu_t + \xi_t, & \xi_t &\sim N(0, \sigma_\xi^2), \\ \nu_{t+1} &= \nu_t + \zeta_t, & \zeta_t &\sim N(0, \sigma_\zeta^2). \end{aligned}$$

Процесс γ_t – это процесс для учёта сезонности, где можно использовать тригонометрические функции или $AR(p)$.

Коэффициенты c_0 и c_μ управляют вкладом сезонности: c_0 задаёт масштаб, а c_μ задаёт изменение сезонности в зависимости от изменения тренда. Конечно же, никто нам не даёт данных μ_t, ν_t – они являются скрытыми, а также c_0 и c_μ .

Пример 5.2. (Радар и оценка положения объекта [3]) В дизайне радара основная идея состоит в замере расстояния до объекта и азимута (направления к объекту). Каждое такое измерение делается с погрешностью и естественно, что при попытке перейти в декартовы координаты эта погрешность (пусть даже гауссовская) претерпевает значительные искажения. Конкретнее, если мы замерили расстояние и азимут r_t, θ_t , то в

декартовых координатах это соответствует точке

$$\begin{bmatrix} x_t \\ y_t \end{bmatrix} = \begin{bmatrix} r_t \cos \theta_t \\ r_t \sin \theta_t \end{bmatrix}.$$

Переменные состояния x_t, y_t рассматриваются как латентные, а расстояние r_t и азимут θ_t наблюдаются с помощью аппаратуры.

Пример 5.3. (Модель навигации транспортного средства [4]) Физика транспортных средств по-настоящему нетривиальна, если делать всё по науке. Если вкратце, то состояние системы Y_t (предполагается движение на плоскости) – это вектор из параметров

$$Y_t = [x_G(t), y_G(t), \psi(t), R(t), F_{yf}(t), F_{yr}(t), C_{\alpha_f}(t), C_{\alpha_r}(t)]^T,$$

где

- $[x_G(t), y_G(t), \psi(t)]^T$ – координаты центра тяжести транспортного средства и курс (угловой);
- $R(t)$ – средний радиус шин.
- $F_{yf}(t), F_{yr}(t)$ – силы тяжести, действующие на передний подвес и задний;
- $C_{\alpha_f}(t), C_{\alpha_r}(t)$ – жёсткость шин.

Сама функция перехода с учётом управления u_{t+1} в момент t принимает очень сложный вид:

$$Y_{t+1} = f(Y_t, u_{t+1}, t + 1),$$

который чисто для зрелищности мы приведём в виде скриншота (но все подробности есть в статье, для соблюдения нотации в этом тексте $Y_k = \mathbf{x}(k)$):

$$\mathbf{f}[\mathbf{x}(k), \mathbf{u}(k+1), k+1] = \begin{bmatrix} x_G(k) + \left(\frac{\sin[\nu(k) + \rho(k)V_G(k)\Delta T] - \sin \nu(k)}{\rho(k)} \right) \\ y_G(k) + \left(\frac{\cos[\nu(k) + \rho(k)V_G(k)\Delta T] - \cos \nu(k)}{\rho(k)} \right) \\ \nu(k) + \rho(k)V_G(k)\Delta T \\ R(k) \\ F_{yf}(k) + \Delta T \Omega \{ \rho(k)mV_G^2(k) \\ + \cos[\delta(k+1) - \beta(k)]F_{yf}(k) - \cos \beta(k)F_{yr}(k) \} \\ F_{yr}(k) + \Delta T \Omega \{ a \cos \delta(k+1)F_{yf}(k) - bF_{yr}(k) \} \\ C_{\alpha_f}(k) \\ C_{\alpha_r}(k) \end{bmatrix}$$

where $\rho(k)$ is the radius of curvature of the motion, $\beta(k)$ is the angle between the course taken by the vehicle and its orientation, and $\alpha_f(k)$ and $\alpha_r(k)$ are the side slip angles. These intermediate quantities are calculated from

$$\begin{aligned} \beta(k) &= \tan^{-1} \left(\frac{b \tan[\delta(k+1) - \alpha_f(k)] - a \tan \alpha_r(k)}{a + b} \right), \\ \rho(k) &= \frac{\sin \beta(k)}{a + b} \{ \tan[\delta(k+1) - \alpha_f(k)] + \tan \alpha_r(k) \}, \\ V_G(k) &= R(k)\omega(k+1) \frac{\cos \delta(k+1)}{\cos \beta(k)}, \\ \alpha_f(k) &= \frac{F_{yf}(k)}{C_{\alpha_f}(k)}, \\ \alpha_r(k) &= \frac{F_{yr}(k)}{C_{\alpha_r}(k)}. \end{aligned}$$

Авторский подход способен оценивать x_G, y_G, ψ с точностью до 1 метра, при этом с первой наивной модернизацией фильтра Калмана (ЕКФ, рассмотрим ниже) результаты значительно хуже.

5.2 Реакция фильтра Калмана на нелинейности

Допущение нелинейности и негауссовости в динамике и наблюдениях требует от нас обобщения предыдущей модели. Как и раньше, величины Y_t представляют собой ненаблюдаемые (латентные) состояния, а X_t наблюдается. Новый набор уравнений выглядит так:

$$\begin{aligned} Y_{t+1} &= f(Y_t, u_t) + V_{t+1} \\ X_{t+1} &= h(Y_{t+1}) + W_{t+1}, \end{aligned}$$

где V_t, W_t представляют собой два независимых процесса белого шума. Также мы сразу для общности учитываем в модели управление u_t , наблюдаемое в момент t воздействие на систему (например, поворот руля автомобиля или уровень тяги двигателя). Можно в этой модели учесть в том числе зависимость f, h от времени, это делается несложно, для краткости формул мы это опустим. Мы полагаем, что у V, W есть ковариации и

$$\mathbb{E}[V_t V_t^T] = R_x, \quad \mathbb{E}[W_t W_t^T] = R_y, \quad \forall t, s \quad \mathbb{E}[V_t W_s^T] = 0.$$

Изначальная идея фильтра Калмана состоит в том, что мы пытаемся оценить условное матожидание и условную ковариацию, используя оценки с предыдущего момента времени.

В идеале мы хотели бы как и раньше иметь

$$\hat{Y}_t = \mathbb{E}[Y_t \mid X_1, \dots, X_t]$$

и

$$P_t = \mathbb{E} \left[(Y_t - \hat{Y}_t)(Y_t - \hat{Y}_t)^T \mid X_1, \dots, X_t \right].$$

Как и раньше, мы можем попробовать строить оценку фильтра в виде

$$\hat{Y}_t = \tilde{Y}_t + K_t(X_t - \tilde{X}_t), \quad \tilde{Y}_t = f(\hat{Y}_{t-1}, u_{t-1}), \quad \tilde{X}_t = h(\tilde{Y}_t),$$

где K_t – коэффициент фильтрации, который выбирается из решения задачи наименьших квадратов. Однако здесь возникает проблема: такого простого рекуррентного уравнения как раньше не возникнет. Можно попробовать выписать один шаг алгоритма.

$$\tilde{Y}_t = f(\hat{Y}_{t-1}, u_{t-1}) = \mathbb{E} \left[f(\hat{Y}_{t-1}, u_{t-1}) \mid X_1, \dots, X_t \right] \quad (\text{априорный прогноз}),$$

$$P_{t-1}^{\hat{Y}, Y} = \mathbb{E} \left[\left(f(\hat{Y}_{t-1}, u_{t-1}) - f(Y_{t-1}, u_{t-1}) \right) \left(f(\hat{Y}_{t-1}, u_{t-1}) - f(Y_{t-1}, u_{t-1}) \right)^T \mid X_1, \dots, X_{t-1} \right],$$

$$\tilde{P}_t = P_{t-1}^{\hat{Y}, Y} + R_y \quad (\text{ошибка априорного прогноза}),$$

$$Z_t = X_t - h(\tilde{Y}_t) = h(Y_t) - h(\tilde{Y}_t) + W_t,$$

$$\hat{Y}_t = \tilde{Y}_t + K_t Z_t \quad (\text{апостериорный прогноз}),$$

$$E_t^{\tilde{Y}, Z} = \mathbb{E} \left[(Y_t - \tilde{Y}_t) Z_t^T \mid X_1, \dots, X_t \right] = \mathbb{E} \left[(Y_t - \tilde{Y}_t) (h(Y_t) - h(\tilde{Y}_t))^T \mid X_1, \dots, X_t \right],$$

$$E_t^{Z, Z} = \mathbb{E} [Z_t Z_t^T \mid X_1, \dots, X_t] = \mathbb{E} [(h(Y_t) - h(\tilde{Y}_t))(h(Y_t) - h(\tilde{Y}_t))^T \mid X_1, \dots, X_t] + R_x,$$

$$K_t = E_t^{\tilde{Y}, Z} \left(E_t^{Z, Z} \right)^{-1} \quad (\text{фильтр})$$

$$\begin{aligned} P_t &= \tilde{P}_t + K_t E_t^{Z, Z} K_t^T - K_t \left(E_t^{\tilde{Y}, Z} \right)^T - E_t^{\tilde{Y}, Z} K_t^T = \\ &= \tilde{P}_t - E_t^{\tilde{Y}, Z} \left(E_t^{Z, Z} \right)^{-1} \left(E_t^{\tilde{Y}, Z} \right)^T \quad (\text{ошибка апостериорного прогноза}). \end{aligned}$$

(ЧЕКНУТЬ МИНУСЫ В ПОСЛЕДНИХ 3 строчках!!) (ЧЕКНУТЬ ВЫРАЖЕНИЕ K_t и P_t) Первое отличие, которое бросается в глаза, – это то, что ошибка априорного прогноза уже не пересчитывается простым образом – нужно считать не считаемое аналитически матожидание, которые мы обозначили $P_{t-1}^{\hat{Y}, Y}$. Такая же проблема возникает на шаге вычисления K_t . Второй момент: мы учитываем только матожидания и ковариацию, что оставляет возможность для обобщения алгоритма, так как более высокие моменты не учитываются. Таким образом, главный корень проблемы, который не позволяет хотя бы как-то запустить эту схему без больших вычислений, – это нелинейность динамики и измерений.

5.3 Алгоритм ЕКФ

Алгоритм ЕКФ (Extended Kalman Filter) сводит нелинейную задачу к линейной путём линеаризации. Конкретнее, рассматривается подход приближения с помощью ряда Тейлора

в окрестности подходящей точки в нелинейных местах.

Нелинейность, которая мешает вычислить один шаг алгоритма, находится всего в трёх выражениях. Это

$$P_{t-1}^{\hat{Y},Y} = \mathbb{E} \left[\left(f(\hat{Y}_{t-1}, u_t) - f(Y_{t-1}, u_t) \right) \left(f(\hat{Y}_{t-1}, u_t) - f(Y_{t-1}, u_t) \right)^T \mid X_1, \dots, X_{t-1} \right],$$

которое пересчитывает новую ошибку на основе старой и

$$E_t^{Z,Z} = \mathbb{E} \left[(h(Y_t) - h(\tilde{Y}_t))(h(Y_t) - h(\tilde{Y}_t))^T \mid X_1, \dots, X_t \right] + R_x,$$

ковариацию невязки наблюдений. Не забываем про ковариацию наблюдений и латентных переменных

$$E_t^{\tilde{Y},Z} = \mathbb{E} \left[(Y_t - \tilde{Y}_t) Z_t^T \mid X_1, \dots, X_t \right] = \mathbb{E} \left[(Y_t - \tilde{Y}_t) (h(Y_t) - h(\tilde{Y}_t))^T \mid X_1, \dots, X_t \right].$$

Идея алгоритма EKF состоит в том, чтобы линеаризовать каждое из этих выражений, используя разложение в ряд Тейлора. В случае функции $h : \mathbb{R}^n \rightarrow \mathbb{R}$ при достаточной её гладкости разложение выглядит так:

$$h(x) = h(x_0) + \nabla_x h|_{x=x_0} \Delta x + \bar{o}(\|\Delta x\|_2), \quad \Delta x = x - x_0.$$

Мы применяем такой подход для этих двух нелинейных выражений и получаем

$$P_{t-1}^{\hat{Y},Y} \approx \nabla f|_{y=\hat{Y}_{t-1}, u=u_{t-1}} \mathbb{E} \left[(Y_{t-1} - \hat{Y}_{t-1}) (Y_{t-1} - \hat{Y}_{t-1})^T \mid X_1, \dots, X_{t-1} \right] \nabla f|_{y=\hat{Y}_{t-1}, u=u_{t-1}}^T,$$

второе выражение примет вид

$$E_t^{\tilde{Y},Z} \approx \mathbb{E} \left[(Y_t - \tilde{Y}_t) (Y_t - \tilde{Y}_t)^T \mid X_1, \dots, X_t \right] \nabla h|_{y=\tilde{Y}_t}^T.$$

Наконец, для $E_t^{Z,Z}$ получим

$$E_t^{Z,Z} \approx \nabla h|_{y=\tilde{Y}_t} \mathbb{E} \left[(Y_t - \tilde{Y}_t) (Y_t - \tilde{Y}_t)^T \mid X_1, \dots, X_t \right] \nabla h|_{y=\tilde{Y}_t}^T + R_x.$$

Алгоритм EKF (Extended Kalman Filter).

$$\begin{aligned}
\tilde{Y}_t &= f(\hat{Y}_{t-1}, u_{t-1}) \quad (\text{априорный прогноз}), \\
P_{t-1}^{\hat{Y}, Y} &= F_{t-1} P_{t-1} F_{t-1}^T, \quad F_{t-1} = \nabla f|_{y=\hat{Y}_{t-1}, u=u_{t-1}}, \\
\tilde{P}_t &= P_{t-1}^{\hat{Y}, Y} + R_y \quad (\text{ошибка априорного прогноза}), \\
Z_t &= X_t - h(\tilde{Y}_t), \\
\hat{Y}_t &= \tilde{Y}_t + K_t Z_t \quad (\text{апостериорный прогноз}), \\
E_t^{\tilde{Y}, Z} &= \tilde{P}_t H_t, \quad H_t = \nabla h|_{y=\tilde{Y}_t}, \\
E_t^{Z, Z} &= H_t \tilde{P}_t H_t^T + R_x, \\
K_t &= E_t^{\tilde{Y}, Z} \left(E_t^{Z, Z} \right)^{-1} \quad (\text{фильтр}) \\
P_t &= \tilde{P}_t + K_t E_t^{Z, Z} K_t^T - K_t \left(E_t^{\tilde{Y}, Z} \right)^T - E_t^{\tilde{Y}, Z} K_t^T = \\
&= \tilde{P}_t - E_t^{\tilde{Y}, Z} \left(E_t^{Z, Z} \right)^{-1} \left(E_t^{\tilde{Y}, Z} \right)^T \quad (\text{ошибка апостериорного прогноза}).
\end{aligned}$$

5.4 Сложности EKF

В общем, линеаризация – такое себе. Это скорее изолента в условиях когда нет чего-то надёжнее. Но как-то работает, а иногда и очень неплохо. Но как демонстрирует задача с радаром, остаётся большая проблема с ковариацией в случае резкой нелинейности.

Литература

- [1] A. P. Dempster, N. M. Laird, and D. B. Rubin. Maximum likelihood from incomplete data via the em algorithm. *Journal of the Royal Statistical Society. Series B (Methodological)*, 39(1):1–38, 1977.
- [2] James Durbin and Siem Jan Koopman. *Time Series Analysis by State Space Methods*, volume None of *OUN Catalogue*. Oxford University Press, 2 edition, None 2012.
- [3] S.J. Julier and J.K. Uhlmann. Unscented filtering and nonlinear estimation. *Proceedings of the IEEE*, 92(3):401–422, 2004.
- [4] S.J. Julier, J.K. Uhlmann, and H.F. Durrant-Whyte. A new approach for filtering nonlinear systems. In *Proceedings of 1995 American Control Conference - ACC'95*, volume 3, pages 1628–1632 vol.3, 1995.
- [5] R. E. Kalman. A New Approach to Linear Filtering and Prediction Problems. *Journal of Basic Engineering*, 82(1):35–45, 03 1960.
- [6] Siem Jan Koopman and Kai Ming Lee. Seasonality with trend and cycle interactions in unobserved components models. *Journal of the Royal Statistical Society: Series C (Applied Statistics)*, 58(4):427–448, 2009.
- [7] Herbert E Rauch, F Tung, and Charlotte T Striebel. Maximum likelihood estimates of linear dynamic systems. *AIAA journal*, 3(8):1445–1450, 1965.
- [8] O. A. Stepanov. Kalman filtering: Past and present. an outlook from russia. (on the occasion of the 80th birthday of rudolf emil kalman). *Gyroscopy and Navigation*, 2(2):99–110, Apr 2011.
- [9] R. L. Stratonovich. Conditional markov processes. *Theory of Probability & Its Applications*, 5(2):156–178, 1960.
- [10] Р.Л. Стратонович. *Условные марковские процессы и их применение к теории оптимального управления*. Московский государственный университет, 1966.