

ЕМ-алгоритм: оценка фильтров

В этой лекции мы попробуем разобраться, как ЕМ-алгоритм помогает оценивать параметры для модели фильтрации и фильтра Калмана.

4.1 Оценка параметров: вывод правдоподобия

Рассмотрим в деталях модель системы; при этом мы без потери основного смысла существенно упростим вычисления: в оригинальной статье Калмана ещё добавлялись управляющие воздействия, которые вносили смещение в шум. Реальные состояния эволюционируют в соответствии с

$$Y_{t+1} = AY_t + V_{t+1},$$

где Y_t, V_t принимают значения в $\mathbb{R}^n$, при этом V_t – это последовательность шумов. Модель наблюдений тоже линейна и со своим шумом:

$$X_{t+1} = BY_{t+1} + W_{t+1}, \quad -$$

про неё мы также предполагаем, что X_t принимает значения в $\mathbb{R}^n$. Матрицы A, B без ограничений, но они должны быть совместимы по размерностям. Про шумы предполагается, что они в совокупности независимы, $V_t \sim \mathcal{N}(0, R_y)$ и $W_t \sim \mathcal{N}(0, R_x)$.

Таким образом, мы имеем вероятностную модель, в которой параметрами θ являются матрицы A, B , ковариационные матрицы векторов шума R_x, R_y , а также параметры стартового состояния $Y_1 \sim \mathcal{N}(\xi, \Lambda)$. Данные включают в себя только набор $X_1, \dots, X_n$; переменные $Y_1, \dots, Y_n$ не наблюдаются.

Время ЕМ-алгоритма! Мы, как и раньше, начинаем с того, что записываем функцию


$$Q(\theta^0 | \theta) := \mathbb{E}_{\theta^0} [\ln p_{\theta}(X, Y) \mid X]$$

и понимаем, что так легко разбить зависимости и выписать условные вероятности, как в случае смеси не получится. Вместо этого мы пойдём более неспешным путём и не будем пока избавляться от матожиданий $\mathbb{E}_{\theta^0} [\cdot \mid X]$.

Начнём с того, что перепишем в точности выражение под знаком матожидания:

$$\ln p_{\theta}(X, Y) = \ln p_{\theta}(X|Y) + \ln p_{\theta}(Y).$$

В данном случае помогает знание зависимостей в величинах X, Y , которые обозначены на рисунке.



Первое слагаемое получается преобразовать как

$$\ln p_{\theta}(X|Y) = \ln p_{\theta}(X_1, \dots, X_{n-1}|X_n, Y) + \ln p_{\theta}(X_n|Y) = \ln p_{\theta}(X_1, \dots, X_{n-1}|Y) + \ln p_{\theta}(X_n|Y_n)$$

и это приводит к привычной сумме

$$\ln p_{\theta}(X|Y) = \sum_{i=1}^n \ln p_{\theta}(X_i|Y_i).$$

Что касается второго, скрытый сигнал Y существует по своей динамике и мы видим что-то похожее на случай цепей Маркова из Лекции 0 (и это не случайность):

$$\ln p_{\theta}(Y) = \ln p_{\theta}(Y_1) + \sum_{i=1}^{n-1} \ln p_{\theta}(Y_{i+1}|Y_i).$$

Таким образом, получается лог-правдоподобие из трёх компонент, в каждую из которых входят свои параметры, общих параметров они не имеют:

$$\ln p_{\theta}(X, Y) = \sum_{i=1}^n \ln p_{\theta}(X_i|Y_i) + \sum_{i=1}^{n-1} \ln p_{\theta}(Y_{i+1}|Y_i) + \ln p_{\theta}(Y_1).$$

Первая очень похожа на правдоподобие гауссовской линейной модели регрессии, вторая – на уже ранее виденную модель авторегрессии (но векторной), а третья связана с неопределённостью стартового состояния.

Если мы воспользуемся теперь явным видом распределений и соберём константы в одну общую константу, получим

$$\begin{aligned} Q(\theta^0|\theta) = & \text{const} - \\ & - \frac{n}{2} \ln \det R_x - \frac{1}{2} \mathbb{E}_{\theta_0} \left[\sum_{i=1}^n \left((X_i - BY_i)^T R_x^{-1} (X_i - BY_i) \mid X \right) \right] - \\ & - \frac{n-1}{2} \ln \det R_y - \frac{1}{2} \mathbb{E}_{\theta_0} \left[\sum_{i=1}^{n-1} (Y_{i+1} - AY_i)^T R_y^{-1} (Y_{i+1} - AY_i) \mid X \right] - \\ & - \frac{1}{2} \ln \det(\Lambda) - \frac{1}{2} (Y_1 - \xi)^T \Lambda^{-1} (Y_1 - \xi). \end{aligned}$$

Здесь очень много всего, но тем не менее есть структура, а если предположить, что все нужные матожидания можно вычислить (мы чуть позже увидим, как именно), то можно явно промаксимизировать по параметрам $\theta = \{A, B, R_x, R_y, \xi, \Lambda\}$. Заметьте, что матожидания берутся по модели данных с параметрами θ^0 , поэтому мы можем вносить производные по θ под знак матожидания.

4.2 Оценка параметров: М-шаг

Все вычисления достаточно технические, их можно без проблем проделать самому, если уметь вычислять матричные производные. Нужные формулы вспомним на ходу. Поскольку шумы гауссовские, то оказывается, что можно в правильном порядке провести дифференцирование, приравнять производные к нулю и получить аналитическое точное решение. Хорошей идеей оказывается адресовать параметры авторегрессионной и регрессионной частей отдельно.

Оптимизируем по A . Матрица A входит только в авторегрессионную компоненту; помним, что дифференцирование можно внести под матожидание, потому что матожидание берётся по модели с A^0 , а не с A . Смотрим на выражение и понимаем, что здесь нам понадобится знакомые с прошлой лекции формула (1)

$$\partial_X \text{tr}(AX) = A$$

и формула (2)

$$\partial_X \text{tr}(XAX^T) = (A + A^T)X^T,$$

а также формула (3):

$$\partial_X \text{tr}(XBX^TR) = BX^TR + B^TX^TR^T.$$

Применим, отбросив не зависящие от A члены:

$$\begin{aligned} \partial_A Q &= \partial_A \mathbb{E}_{\theta^0} \left[\frac{1}{2} \sum_{i=1}^{n-1} (Y_{i+1}^T R_y^{-1} Y_{i+1} - Y_i^T A^T R_y^{-1} Y_{i+1} - Y_{i+1}^T R_y^{-1} A Y_i + Y_i^T A^T R_y^{-1} A Y_i) \mid X \right] = \\ &= \sum_{i=1}^{n-1} (\mathbb{E}_{\theta^0} [Y_i Y_{i+1}^T \mid X] R_y^{-1} - \mathbb{E}_{\theta^0} [Y_i Y_i^T \mid X] A^T R_y^{-1}). \end{aligned}$$

Если приравняем к нулю и произведём сокращения, то получим, что оптимальная

$$A = \left(\sum_{i=1}^{n-1} P_{i+1,i} \right) \left(\sum_{i=1}^{n-1} P_{i,i} \right)^{-1}, \quad P_{i,i} = \mathbb{E}_{\theta^0} [Y_i Y_i^T \mid X], \quad P_{i+1,i} = \mathbb{E}_{\theta^0} [Y_{i+1} Y_i^T \mid X],$$

тут мы впервые ввели для краткости новое обозначение $P_{i,i}$ и $P_{i+1,i}$.

Оптимизируем по R_y . Здесь нам понадобится знакомая по гауссовскому ММП формула (3) для

$$\partial_C \ln \det(C) = (C^T)^{-1}.$$

В итоге получим

$$\partial_{R_y} Q = -\frac{n-1}{2} R_y^{-1} + \frac{1}{2} \sum_{i=1}^{n-1} (R_y^{-1} P_{i+1,i+1} R_y^{-1} - R_y^{-1} A P_{i,i+1} R_y^{-1} - R_y^{-1} P_{i+1,i} A^T R_y^{-1} + R_y^{-1} A P_{i,i} A^T R_y^{-1})$$

и, приравняв к нулю и сократив лишнее, придём к результату

$$R_y = \frac{1}{n-1} \sum_{i=1}^{n-1} (-A P_{i,i+1} - P_{i+1,i} A^T + P_{i+1,i+1} + A P_{i,i} A^T).$$

Впрочем, можно и сразу применить формулу для производной следа. Здесь всё, как в знакомом $VAR(1)$.


Оптимизируем по B и R_x . Здесь всё происходит абсолютно по тем же принципам, но возникнут произведения X и Y . Выпишем просто ответ:

$$B = \left(\sum_{i=1}^n \widetilde{x} y_i \right) \left(\sum_{i=1}^n P_{i,i} \right)^{-1}, \quad R_x = \frac{1}{n} \sum_{i=1}^n \left(X_i X_i^T + B P_{i,i} B^T - B \widetilde{x} y_i^T - \widetilde{x} y_i B^T \right),$$

где мы по аналогии с $P_{i,i}$ ввели

$$\widetilde{x} y_i = \mathbb{E}_{\theta^0} [X_i Y_i^T \mid X].$$

В итоге. Мы получили формулы для вычисления М-шага, но проблема в том, что все они зависят от матожиданий, которые мы пока не вычисляли. На первый взгляд это кажется сложной задачей, потому что самый прямой подход требует вычисления условного распределения по аналогии с тем, как мы делали в случае смесей.



4.3 Алгоритм фильтрации Калмана

Не случайность, что ровно такие матожидания вычислялись в фильтре Калмана! Конкретнее, в алгоритме RTSS (сглаживание). Если мы будем использовать алгоритм Калмана и RTSS, на выходе мы получим ровно нужные величины и завершим конструкцию ЕМ-алгоритма. Его можно будет пробовать запускать.

Вспомним модель как раньше, но с известными параметрами $A, B, R_x, R_y, \Lambda, \xi$ (они нам даны в θ_0 , такова конструкция ЕМ-алгоритма).

$$\begin{aligned} Y_{t+1} &= AY_t + V_{t+1}, \quad V_{t+1} \sim \mathcal{N}(0, R_y), \\ X_{t+1} &= BY_{t+1} + W_{t+1}, \quad W_{t+1} \sim \mathcal{N}(0, R_x). \end{aligned}$$

4.3.1 Финальный алгоритм

Фильтрация. Итак, алгоритм фильтрации Калмана. Задаём из параметров θ_0 (по конструкции ЕМ-алгоритма они даны) $\tilde{Y}_1 = \xi, \tilde{P}_1 = \Lambda$, а далее в цикле по t (на шаге $t = 1$ первые два действия задаются инициализацией):

$$\begin{aligned} \tilde{Y}_t &= A\tilde{Y}_{t-1} \quad (\text{априорный прогноз}), \\ \tilde{P}_t &= A\tilde{P}_{t-1}A^T + R_y \quad (\text{ошибка априорного прогноза}), \\ K_t &= \tilde{P}_t B^T (B\tilde{P}_t B^T + R_x)^{-1} \quad (\text{фильтр}) \\ \hat{Y}_t &= \tilde{Y}_t + K_t (X_t - B\tilde{Y}_t) \quad (\text{апостериорный прогноз}), \\ P_t &= \tilde{P}_t - K_t B \tilde{P}_t \quad (\text{ошибка апостериорного прогноза}). \end{aligned}$$

Сглаживание. Фильтрации нам мало, потому что она вычисляет только

$$\hat{Y}_t = \mathbb{E}[Y_t \mid X_1, \dots, X_t],$$

то есть, условное матожидание при условии моментов времени до t . Чтобы уточнить старые прогнозы фильтрации применяют алгоритм сглаживания (RTSS), а ещё дополнительно нам нужно вычислять ковариацию значений с лагом (детали опустим, формулу нужно получать из RTSS). По инструкции: задать $\bar{Y}_T = \hat{Y}_T, \bar{P}_T = P_T$, а далее в цикле $t = T - 1, \dots, 1$ выполнять

$$\begin{aligned} S_t &= P_t A^T (\tilde{P}_{t+1})^{-1} \quad (\text{вычисление сглаживающего фильтра}), \\ \bar{Y}_t &= \hat{Y}_t + S_t (\bar{Y}_{t+1} - \tilde{Y}_{t+1}) \quad (\text{сглаживание}), \\ \bar{P}_t &= P_t + S_t (\bar{P}_{t+1} - \tilde{P}_{t+1}) S_t^T \quad (\text{ошибка сглаживания}), \\ V_{t+1,t} &= S_t \bar{P}_t, \quad (\text{лаг-1 ковариация, для } t \leq T - 1) \end{aligned}$$

Финальная схема. Остаётся только понять, как алгоритм фильтрации помогает построить ЕМ-алгоритм. Если вернуться немного назад, то интересные матожидания можно найти в расчётах:

$$P_{i,i} = \bar{P}_i + \hat{Y}_i \hat{Y}_i^T, \quad P_{i+1,i} = V_{i+1,i} + \hat{Y}_{i+1} \hat{Y}_i^T,$$

а кросс-члены в силу известных наблюдений X задаются как


$$\widetilde{yx}_i = \hat{Y}_i X_i^T.$$

Итоговый ЕМ-алгоритм выглядит теперь так:

1. Инициализировать $\theta^0 = \{A, B, R_x, R_y, \xi, \Lambda\}$;
2. Пока не остановимся:
 - (а) Е-шаг: Вычислить матожидания из формул на основе параметров θ^0 , используя алгоритм фильтрации и сглаживания;
 - (б) М-шаг: вычислить новые параметры θ по выведенным формулам.

4.3.2 Проблемы

...такой алгоритм может не сойтись. Если оценивать всё, то в системе очень много степеней свободы. Заметьте, к примеру, что матрицы A и B могут друг друга компенсировать и друг под друга подгоняться. Например, на шаге 10 матрица A диагональная с 10 на диагонали, матрица B – с числом $1/10$; если они поменяются местами и правильно пересчитаются ковариационные матрицы R_x, R_y , то правдоподобие не изменится. На практике это соответствует тому, что наблюдатель Y меряет в килограммах интересное значение, а наблюдающий X меряет значение в тоннах; а на более поздней итерации наоборот. Чтобы избежать этой проблемы достаточно зафиксировать одну из матриц, например, единичной. К счастью, в любой задаче для фильтра у вас уже есть априорная информация, позволяющая оценивать только часть неизвестных параметров. В этом случае алгоритм уже сойдётся и так будет выглядеть его результат после 100 итераций (доверительный интервал уровня 0.975 построен с использованием оценки апостериорной ошибки):



На этой картинке изображена задача фильтрации GPS датчика из семинара. В качестве наблюдений дана только координата (скорость не замеряется), требуется оценить траекторию и скорость объекта в каждый момент времени. На левом графике показан результат для координаты, а на правой – для скорости. Если вдруг вы линейный скептик (и не верите в линейные модели), фильтр Калмана – тот самый случай, когда линейная модель способна на по-настоящему реальные вещи.

Литература

- [1] A. P. Dempster, N. M. Laird, and D. B. Rubin. Maximum likelihood from incomplete data via the em algorithm. *Journal of the Royal Statistical Society. Series B (Methodological)*, 39(1):1–38, 1977.
- [2] James Durbin and Siem Jan Koopman. *Time Series Analysis by State Space Methods*, volume None of *OUN Catalogue*. Oxford University Press, 2 edition, None 2012.
- [3] S.J. Julier and J.K. Uhlmann. Unscented filtering and nonlinear estimation. *Proceedings of the IEEE*, 92(3):401–422, 2004.
- [4] S.J. Julier, J.K. Uhlmann, and H.F. Durrant-Whyte. A new approach for filtering nonlinear systems. In *Proceedings of 1995 American Control Conference - ACC'95*, volume 3, pages 1628–1632 vol.3, 1995.
- [5] R. E. Kalman. A New Approach to Linear Filtering and Prediction Problems. *Journal of Basic Engineering*, 82(1):35–45, 03 1960.
- [6] Siem Jan Koopman and Kai Ming Lee. Seasonality with trend and cycle interactions in unobserved components models. *Journal of the Royal Statistical Society: Series C (Applied Statistics)*, 58(4):427–448, 2009.
- [7] Herbert E Rauch, F Tung, and Charlotte T Striebel. Maximum likelihood estimates of linear dynamic systems. *AIAA journal*, 3(8):1445–1450, 1965.
- [8] O. A. Stepanov. Kalman filtering: Past and present. an outlook from russia. (on the occasion of the 80th birthday of rudolf emil kalman). *Gyroscopy and Navigation*, 2(2):99–110, Apr 2011.
- [9] R. L. Stratonovich. Conditional markov processes. *Theory of Probability & Its Applications*, 5(2):156–178, 1960.
- [10] Р.Л. Стратонович. *Условные марковские процессы и их применение к теории оптимального управления*. Московский государственный университет, 1966.