

Нелинейность: расширенный фильтр Калмана (ЕКФ)

В этой лекции мы посмотрим внимательнее на модельное предположение линейности и обсудим, до какой степени мы можем обобщить оригинальный алгоритм фильтра Калмана.

5.1 Проблемы линейной модели

Фильтр Калмана – действительно по-настоящему мощная линейная модель и может сложиться впечатление, что для него нет нерешаемых задач. До какой-то степени это действительно верно, но как и любой метод, он обладает некоторыми недостатками и для определённых задач невозможно их полностью игнорировать.

- **Нелинейность.** Так складывается, что по построению многие практические модели оказываются нелинейными. Учитывая, как далеко прошли технологии в области средств передвижения, навигации и измерений, это неудивительно. Хотите применить фильтрацию – нужно учитывать конструктивные особенности.
- **Негауссовость.** Несмотря на достаточное удобство гауссовского распределения, некоторые процессы устроены по-другому. В частности, это касается моделей, используемых в финансовой математике, а также в актуарных расчётах.

Для второй проблемы мы всё ещё имеем гарантии того, что фильтр Калмана даёт наилучшую *линейную* оценку в смысле L^2 , но наилучшая оценка в L^2 вообще может быть сложнее. Первую проблему в зависимости от приложений до какой-то степени можно решить дополнительными датчиками и дополнительными *экзогенными* индикаторами, которые позволяют учесть всю нелинейность в виде готовых значений. Но всё же этот путь дорогой (нужно включать в систему сложнее устройства, проводить более сложные опросы, вытаскивать очень специфичные данные), а ещё очень часто оказывается, что даже на уровне концепции от нелинейной динамики не уйти.

Но от этого задача фильтрации не становится невыполнимой и уж точно не теряет своей актуальности. Наоборот, всё становится ещё интереснее и появляется много вопросов о том, как именно в своей задаче учитывать эти ограничения, чтобы адаптировать к ним общую методологию.

Пример 5.1. (Путёвки за границу Великобритании [2, Гл.14]) Логарифмирование и переход к лог-приращениям – один из самых популярных приёмов в анализе временных рядов. Однако, даже после него могут оставаться сезонные и трендовые компоненты, которые приводят к нелинейной системе. В качестве примера рассматриваются наблюдения за количеством выездов жителей Соединённого Королевства с января 1980 до декабря 2006, собранные Национальной службой статистики (ONS). Уже на первых графиках (здесь мы их приводим для полноты) видно, что логарифмирование не очень помогает: в течение ряда в какие-то моменты тренд начинает доминировать сезонность.




Иллюстрация из примера: на графике выше показано число выездов (в миллионах), ниже – логарифмированный ряд, масштаб данных месячный

В статье [6] рассматривается следующая модель (логарифмированного либо исходного) ряда:

$$y_t = \mu_t + \exp(c_0 + c_\mu \mu_t) \gamma_t + \varepsilon_t, \quad \varepsilon_t \sim N(0, \sigma_\varepsilon^2), \quad t = 1, \dots, n,$$

где c_0, c_μ неизвестные коэффициенты. Процесс μ_t – это процесс локального линейного тренда

$$\begin{aligned} \mu_{t+1} &= \mu_t + \nu_t + \xi_t, & \xi_t &\sim N(0, \sigma_\xi^2), \\ \nu_{t+1} &= \nu_t + \zeta_t, & \zeta_t &\sim N(0, \sigma_\zeta^2). \end{aligned}$$

Процесс γ_t – это процесс для учёта сезонности, где можно использовать тригонометрические функции или $AR(p)$.

Коэффициенты c_0 и c_μ управляют вкладом сезонности: c_0 задаёт масштаб, а c_μ задаёт

изменение сезонности в зависимости от изменения тренда. Конечно же, никто нам не даёт данных μ_t, ν_t – они являются скрытыми, а также c_0 и c_μ . Это тот момент, когда в дело вступают сложные процедуры оценивания, основанные на МСМС (Markov Chain Monte Carlo) и байесовской фильтрации. Основной вклад статьи в том, что удалось построить вычислительно более приятный метод без использования этих инструментов.

Пример 5.2. (Радар и оценка положения объекта [3]) В дизайне радара основная идея состоит в замере расстояния до объекта и азимута (направления к объекту). Каждое такое измерение делается с погрешностью и естественно, что при попытке перейти в декартовы координаты эта погрешность (пусть даже гауссовская) претерпевает значительные искажения. Конкретнее, если мы замерили расстояние и азимут r_t, θ_t , то в декартовых координатах это соответствует точке

$$\begin{bmatrix} x_t \\ y_t \end{bmatrix} = \begin{bmatrix} r_t \cos \theta_t \\ r_t \sin \theta_t \end{bmatrix}.$$

Переменные состояния x_t, y_t рассматриваются как латентные, а расстояние r_t и азимут θ_t наблюдаются с помощью аппаратуры. В приложениях, связанных с робототехникой известна задача SLAM (Simultaneous Localization and Mapping, одновременная локализация и картирование), которая тоже обладает такими нелинейными эффектами.

Пример 5.3. (Модель навигации транспортного средства [4]) Физика транспортных средств по-настоящему нетривиальна, если делать всё по науке. Если вкратце, то состояние системы Y_t (предполагается движение на плоскости) – это вектор из параметров

$$Y_t = [x_G(t), y_G(t), \psi(t), R(t), F_{yf}(t), F_{yr}(t), C_{\alpha_f}(t), C_{\alpha_r}(t)]^T,$$

где

- $[x_G(t), y_G(t), \psi(t)]^T$ – координаты центра тяжести транспортного средства и курс (угловой);
- $R(t)$ – средний радиус шин.
- $F_{yf}(t), F_{yr}(t)$ – силы тяжести, действующие на передний подвес и задний;
- $C_{\alpha_f}(t), C_{\alpha_r}(t)$ – жёсткость шин.

Сама функция перехода с учётом управления u_{t+1} в момент t принимает очень сложный вид:

$$Y_{t+1} = f(Y_t, u_{t+1}, t + 1),$$

который чисто для зрелищности мы приведём в виде скриншота (но все подробности есть в статье, для соблюдения нотации в этом тексте $Y_k = \mathbf{x}(k)$):

$$\mathbf{f}[\mathbf{x}(k), \mathbf{u}(k+1), k+1] = \begin{bmatrix} x_G(k) + \left(\frac{\sin[\nu(k) + \rho(k)V_G(k)\Delta T] - \sin \nu(k)}{\rho(k)} \right) \\ y_G(k) + \left(\frac{\cos[\nu(k) + \rho(k)V_G(k)\Delta T] - \cos \nu(k)}{\rho(k)} \right) \\ \nu(k) + \rho(k)V_G(k)\Delta T \\ R(k) \\ F_{yf}(k) + \Delta T \Omega \{ \rho(k)mV_G^2(k) \\ + \cos[\delta(k+1) - \beta(k)]F_{yf}(k) - \cos \beta(k)F_{yr}(k) \} \\ F_{yr}(k) + \Delta T \Omega \{ a \cos \delta(k+1)F_{yf}(k) - bF_{yr}(k) \} \\ C_{\alpha_f}(k) \\ C_{\alpha_r}(k) \end{bmatrix}$$

where $\rho(k)$ is the radius of curvature of the motion, $\beta(k)$ is the angle between the course taken by the vehicle and its orientation, and $\alpha_f(k)$ and $\alpha_r(k)$ are the side slip angles. These intermediate quantities are calculated from

$$\begin{aligned} \beta(k) &= \tan^{-1} \left(\frac{b \tan[\delta(k+1) - \alpha_f(k)] - a \tan \alpha_r(k)}{a + b} \right), \\ \rho(k) &= \frac{\sin \beta(k)}{a + b} \{ \tan[\delta(k+1) - \alpha_f(k)] + \tan \alpha_r(k) \}, \\ V_G(k) &= R(k)\omega(k+1) \frac{\cos \delta(k+1)}{\cos \beta(k)}, \\ \alpha_f(k) &= \frac{F_{yf}(k)}{C_{\alpha_f}(k)}, \\ \alpha_r(k) &= \frac{F_{yr}(k)}{C_{\alpha_r}(k)}. \end{aligned}$$

Проблема в том, что наблюдаем мы что-то совсем грубое (приборы и GPS), а хотим узнать что-то максимально близкое к физике (скорости, ускорения и другое). Авторский подход способен оценивать x_G, y_G, ψ с точностью до 1 метра, при этом с первой наивной модернизацией фильтра Калмана (ЕКФ, рассмотрим ниже) результаты значительно хуже.

5.2 Реакция фильтра Калмана на нелинейности

Допущение нелинейности и негауссовости в динамике и наблюдениях требует от нас обобщения предыдущей модели. Как и раньше, величины Y_t представляют собой ненаблюдаемые (латентные) состояния, а X_t наблюдается. Новый набор уравнений выглядит так:

$$\begin{aligned} Y_{t+1} &= f(Y_t, u_t) + V_{t+1} \\ X_{t+1} &= h(Y_{t+1}) + W_{t+1}, \end{aligned}$$

где V_t, W_t представляют собой два независимых процесса белого шума. Также мы сразу для общности учитываем в модели управление u_t , наблюдаемое в момент t воздействие на систему (например, поворот руля автомобиля или уровень тяги двигателя). Можно в этой модели учесть в том числе зависимость f, h от времени, это делается несложно, для краткости формул мы это опустим. Мы полагаем, что у V, W есть ковариации и

$$\mathbb{E}[V_t V_t^T] = R_y, \quad \mathbb{E}[W_t W_t^T] = R_x, \quad \forall t, s \quad \mathbb{E}[V_t W_s^T] = 0.$$

Изначальная идея фильтра Калмана состоит в том, что мы пытаемся оценить условное матожидание и условную ковариацию, используя оценки с предыдущего момента времени.

В идеале мы хотели бы как и раньше иметь

$$\hat{Y}_t = \mathbb{E}[Y_t \mid X_1, \dots, X_t]$$

и

$$P_t = \mathbb{E}[(Y_t - \hat{Y}_t)(Y_t - \hat{Y}_t)^T \mid X_1, \dots, X_t].$$

Как и раньше, мы можем попробовать строить оценку фильтра в виде

$$\hat{Y}_t = \tilde{Y}_t + K_t(X_t - \tilde{X}_t), \quad \tilde{Y}_t = f(\hat{Y}_{t-1}, u_{t-1}), \quad \tilde{X}_t = h(\tilde{Y}_t),$$

где K_t – коэффициент фильтрации, который выбирается из решения задачи наименьших квадратов. Однако здесь возникает проблема: такого простого рекуррентного уравнения как раньше не возникнет. Можно попробовать выписать один шаг алгоритма. Оказывается, такой подход, на первый взгляд дешёво расширяющий предыдущую методологию на нелинейный случай, может быть в том числе получен из более общих рекуррентных соотношений Стратоновича для апостериорных мер [13], которые можно в компактном виде, найти в [8] и в [7].

$$\tilde{Y}_t = f(\hat{Y}_{t-1}, u_{t-1}) = \mathbb{E}[f(\hat{Y}_{t-1}, u_{t-1}) \mid X_1, \dots, X_{t-1}] \quad (\text{априорный прогноз}),$$

$$P_{t-1}^{\tilde{Y}, Y} = \mathbb{E}\left[\left(f(\hat{Y}_{t-1}, u_{t-1}) - f(Y_{t-1}, u_{t-1})\right)\left(f(\hat{Y}_{t-1}, u_{t-1}) - f(Y_{t-1}, u_{t-1})\right)^T \mid X_1, \dots, X_{t-1}\right],$$

$$\tilde{P}_t = P_{t-1}^{\tilde{Y}, Y} + R_y \quad (\text{ошибка априорного прогноза}),$$

$$Z_t = X_t - h(\tilde{Y}_t) = h(Y_t) - h(\tilde{Y}_t) + W_t,$$

$$\hat{Y}_t = \tilde{Y}_t + K_t Z_t \quad (\text{апостериорный прогноз}),$$

$$E_t^{\tilde{Y}, Z} = \mathbb{E}\left[(Y_t - \tilde{Y}_t) Z_t^T \mid X_1, \dots, X_{t-1}\right] = \mathbb{E}\left[(Y_t - \tilde{Y}_t)(h(Y_t) - h(\tilde{Y}_t))^T \mid X_1, \dots, X_{t-1}\right],$$

$$E_t^{Z, Z} = \mathbb{E}[Z_t Z_t^T \mid X_1, \dots, X_{t-1}] = \mathbb{E}[(h(Y_t) - h(\tilde{Y}_t))(h(Y_t) - h(\tilde{Y}_t))^T \mid X_1, \dots, X_{t-1}] + R_x,$$

$$K_t = E_t^{\tilde{Y}, Z} (E_t^{Z, Z})^{-1} \quad (\text{фильтр})$$

$$P_t = \tilde{P}_t + K_t E_t^{Z, Z} K_t^T - K_t (E_t^{\tilde{Y}, Z})^T - E_t^{\tilde{Y}, Z} K_t^T =$$

$$= \tilde{P}_t - E_t^{\tilde{Y}, Z} (E_t^{Z, Z})^{-1} (E_t^{\tilde{Y}, Z})^T \quad (\text{ошибка апостериорного прогноза}).$$

Прежде всего, замените мысленно f, h на линейные функции – получите тот же привычный линейный фильтр Калмана. Главное отличие, которое бросается в глаза, – это то, что ошибка априорного прогноза уже не пересчитывается простым образом – нужно считать не считаемое аналитически матожидание, которые мы обозначили $P_{t-1}^{\tilde{Y}, Y}$. Такая же проблема возникает на шаге вычисления K_t . Таким образом, корень проблемы, который не позволяет хотя бы как-то запустить эту схему без больших вычислений, – это нелинейность динамики и измерений.

5.3 Алгоритм ЕКФ

Сложно сказать, когда впервые в мире применили алгоритм ЕКФ (Extended Kalman Filter), который сводит нелинейную задачу к линейной путём линеаризации. Легенды говорят, что подобные подходы развивались на уровне техник и практик (know-how) во время космической гонки: в США и СССР. Конкретнее, рассматривается подход приближения с помощью ряда Тейлора в окрестности подходящей точки в нелинейных местах.

Нелинейность, которая мешает вычислить один шаг алгоритма, находится всего в трёх выражениях. Это

$$P_{t-1}^{\hat{Y},Y} = \mathbb{E} \left[\left(f(\hat{Y}_{t-1}, u_t) - f(Y_{t-1}, u_t) \right) \left(f(\hat{Y}_{t-1}, u_t) - f(Y_{t-1}, u_t) \right)^T \mid X_1, \dots, X_{t-1} \right],$$

которое пересчитывает новую ошибку на основе старой и

$$E_t^{Z,Z} = \mathbb{E} \left[(h(Y_t) - h(\tilde{Y}_t))(h(Y_t) - h(\tilde{Y}_t))^T \mid X_1, \dots, X_{t-1} \right] + R_x,$$

ковариацию невязки наблюдений. Не забываем про ковариацию наблюдений и латентных переменных

$$E_t^{\tilde{Y},Z} = \mathbb{E} \left[(Y_t - \tilde{Y}_t) Z_t^T \mid X_1, \dots, X_{t-1} \right] = \mathbb{E} \left[(Y_t - \tilde{Y}_t) (h(Y_t) - h(\tilde{Y}_t))^T \mid X_1, \dots, X_{t-1} \right].$$

Идея алгоритма ЕКФ состоит в том, чтобы линеаризовать каждое из этих выражений, используя разложение в ряд Тейлора. В случае функции $h : \mathbb{R}^n \rightarrow \mathbb{R}$ при достаточной её гладкости разложение выглядит так:

$$h(x) = h(x_0) + \nabla_x h|_{x=x_0} \Delta x + \bar{o}(\|\Delta x\|_2), \quad \Delta x = x - x_0.$$

Мы применяем такой подход для этих двух нелинейных выражений и получаем

$$P_{t-1}^{\hat{Y},Y} \approx \nabla f|_{y=\hat{Y}_{t-1}, u=u_{t-1}} \mathbb{E} \left[(Y_{t-1} - \hat{Y}_{t-1}) (Y_{t-1} - \hat{Y}_{t-1})^T \mid X_1, \dots, X_{t-1} \right] \nabla f|_{y=\hat{Y}_{t-1}, u=u_{t-1}}^T,$$

второе выражение примет вид

$$E_t^{\tilde{Y},Z} \approx \mathbb{E} \left[(Y_t - \tilde{Y}_t) (Y_t - \tilde{Y}_t)^T \mid X_1, \dots, X_t \right] \nabla h|_{y=\tilde{Y}_t}^T.$$

Наконец, для $E_t^{Z,Z}$ получим

$$E_t^{Z,Z} \approx \nabla h|_{y=\tilde{Y}_t} \mathbb{E} \left[(Y_t - \tilde{Y}_t) (Y_t - \tilde{Y}_t)^T \mid X_1, \dots, X_{t-1} \right] \nabla h|_{y=\tilde{Y}_t}^T + R_x.$$

Алгоритм EKF (Extended Kalman Filter).

$$\begin{aligned}
\tilde{Y}_t &= f(\hat{Y}_{t-1}, u_{t-1}) \quad (\text{априорный прогноз}), \\
P_{t-1}^{\tilde{Y},Y} &= F_{t-1}P_{t-1}F_{t-1}^T, \quad F_{t-1} = \nabla f|_{y=\hat{Y}_{t-1}, u=u_{t-1}}, \\
\tilde{P}_t &= P_{t-1}^{\tilde{Y},Y} + R_y \quad (\text{ошибка априорного прогноза}), \\
Z_t &= X_t - h(\tilde{Y}_t), \\
\hat{Y}_t &= \tilde{Y}_t + K_t Z_t \quad (\text{апостериорный прогноз}), \\
E_t^{\tilde{Y},Z} &= \tilde{P}_t H_t, \quad H_t = \nabla h|_{y=\tilde{Y}_t}, \\
E_t^{Z,Z} &= H_t \tilde{P}_t H_t^T + R_x, \\
K_t &= E_t^{\tilde{Y},Z} \left(E_t^{Z,Z} \right)^{-1} \quad (\text{фильтр}) \\
P_t &= \tilde{P}_t - E_t^{\tilde{Y},Z} \left(E_t^{Z,Z} \right)^{-1} \left(E_t^{\tilde{Y},Z} \right)^T \quad (\text{ошибка апостериорного прогноза}).
\end{aligned}$$

Почти оригинальный фильтр Калмана, но нелинейность используется очень выборочно. Опять же, если взять линейные функции f, h , то мы получим оригинальный фильтр Калмана.

5.4 Сложности EKF

EKF на момент начала 2000-х [10, 3], и даже сейчас является стандартно и широко применимой методологией на практике. Действительно, локальная линейаризация позволяет добиться ощутимых результатов по цене вычислений линейного фильтра Калмана. Однако этот подход изначально очень сильно опирается на предположение хорошей локальной линейаризуемости системы. Данный метод, хотя позволяет достичь некоторого успеха, имеет серьёзные проблемы.

1. Алгоритм EKF приводит к очень нестабильным оценкам в случае, когда предположение локальной линейаризуемости выполняется слабо. В частности, один из простых примеров – тот самый пример с радаром и переводом из полярных координат в декартовы, который мы рассматривали в начале.
2. Вычисление матрицы Якоби может быть очень нетривиальным и вызывать проблемы как на этапе имплементации, так и на этапе вывода формул.

Усилия науки в последние десятилетия были направлены на то, чтобы решить эти проблемы самыми разными способами, но оказывается, что универсальной методологии, которая позволила бы дёшево решить эти проблемы, на текущий момент пока до сих пор нет и скорее всего не будет. В общем, линейаризация, как часто бывает, скорее является изоляцией в условиях когда нет чего-то надёжнее.

Но есть ещё одна универсальная методология, которая ценой немного больших вычислений позволяет элегантно обойти проблему пересчёта ковариационной матрицы и получить более точные оценки. Это алгоритм UKF, который был предложен в конце 90-х годов, спустя больше 30 лет после изобретения фильтра Калмана.

Литература

- [1] A. P. Dempster, N. M. Laird, and D. B. Rubin. Maximum likelihood from incomplete data via the em algorithm. *Journal of the Royal Statistical Society. Series B (Methodological)*, 39(1):1–38, 1977.
- [2] James Durbin and Siem Jan Koopman. *Time Series Analysis by State Space Methods*, volume None of *OUN Catalogue*. Oxford University Press, 2 edition, None 2012.
- [3] S.J. Julier and J.K. Uhlmann. Unscented filtering and nonlinear estimation. *Proceedings of the IEEE*, 92(3):401–422, 2004.
- [4] S.J. Julier, J.K. Uhlmann, and H.F. Durrant-Whyte. A new approach for filtering nonlinear systems. In *Proceedings of 1995 American Control Conference - ACC'95*, volume 3, pages 1628–1632 vol.3, 1995.
- [5] R. E. Kalman. A New Approach to Linear Filtering and Prediction Problems. *Journal of Basic Engineering*, 82(1):35–45, 03 1960.
- [6] Siem Jan Koopman and Kai Ming Lee. Seasonality with trend and cycle interactions in unobserved components models. *Journal of the Royal Statistical Society: Series C (Applied Statistics)*, 58(4):427–448, 2009.
- [7] Vladimir Man'Ko and Liubov Markovich. Optimal nonlinear filtering of quantum state. *IEEE Transactions on Information Theory*, 64(7):4784–4791, 2018.
- [8] Liubov A. Markovich. Inferences from optimal filtering equation*. *Lithuanian Mathematical Journal*, 55(3):413–432, Jul 2015.
- [9] Herbert E Rauch, F Tung, and Charlotte T Striebel. Maximum likelihood estimates of linear dynamic systems. *AIAA journal*, 3(8):1445–1450, 1965.
- [10] H.W. Sorenson. *Kalman Filtering: Theory and Application*. IEEE Press selected reprint series. IEEE Press, 1985.
- [11] O. A. Stepanov. Kalman filtering: Past and present. an outlook from russia. (on the occasion of the 80th birthday of rudolf emil kalman). *Gyroscopy and Navigation*, 2(2):99–110, Apr 2011.
- [12] R. L. Stratonovich. Conditional markov processes. *Theory of Probability & Its Applications*, 5(2):156–178, 1960.
- [13] Р.Л. Стратонович. *Условные марковские процессы и их применение к теории оптимального управления*. Московский государственный университет, 1966.